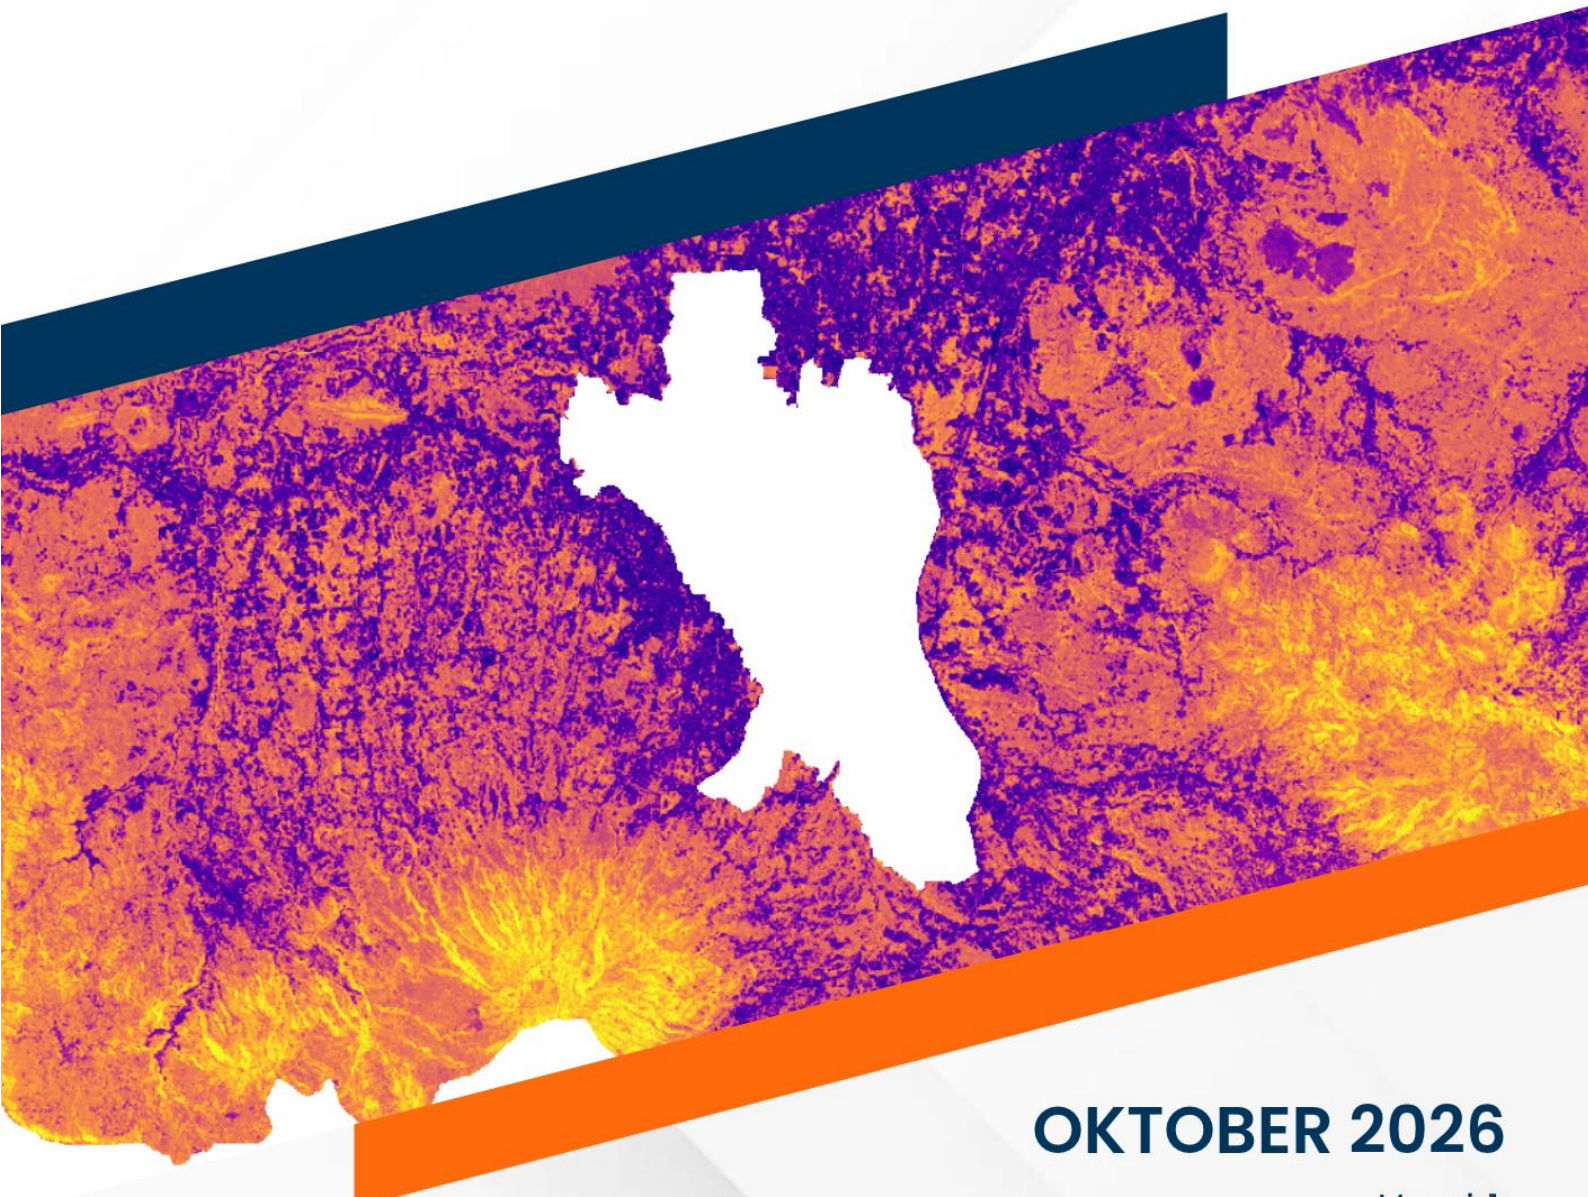
# TECHNICAL REPORT

## PEMETAAN ABOVEGROUND BIOMASS DENSITY (AGBD) KABUPATEN BOGOR BERBASIS STAC API



**OKTOBER 2026**

Versi 1

## Ringkasan Eksklusif

*Aboveground Biomass Density* (AGBD) merupakan kepadatan biomassa vegetasi hidup di atas permukaan tanah per satuan luas yang penting untuk pemantauan stok karbon dan degradasi hutan. Inventarisasi lapangan memerlukan biaya tinggi dengan cakupan terbatas, sedangkan penggunaan satu jenis sensor satelit belum memadai bagi wilayah tropis berawan dan bertopografi beragam seperti Kabupaten Bogor, Jawa Barat. Laporan ini mendokumentasikan pengembangan alur kerja estimasi AGBD beresolusi 30 meter yang memadukan data multisensor. Citra Sentinel-2, Sentinel-1, elevasi Copernicus DEM GLO-30, dan probabilitas tutupan lahan Dynamic World yang diperoleh melalui *SpatioTemporal Asset Catalog* (STAC) API diolah menjadi 34 fitur prediktor pada grid UTM Zona 48S, sedangkan data LiDAR antariksa GEDI L4A dari *National Aeronautics and Space Administration* (NASA) digunakan sebagai label AGBD. Model Random Forest Regressor dengan 350 pohon keputusan dilatih menggunakan pembagian acak 80 persen data latih dan 20 persen data uji. Pada data uji, model menghasilkan koefisien determinasi ($R^2$) sebesar 0,646, *Root Mean Squared Error* (RMSE) sebesar 39,07 Mg/ha atau 50,31 persen secara relatif, dan *Mean Absolute Percentage Error* (MAPE) sebesar 32,93 persen. Model tersebut kemudian digunakan untuk inferensi spasial pada wilayah sampel dan menghasilkan peta AGBD dengan *masking* area non-vegetasi berdasarkan klasifikasi Dynamic World. Hasil ini menunjukkan bahwa integrasi data multisensor dengan Random Forest mampu menghasilkan peta AGBD beresolusi 30 meter sebagai estimasi regional awal. Namun, label bersumber dari estimasi model GEDI L4A, pembagian data secara acak berpotensi menghasilkan skor yang lebih optimistis, dan validasi lapangan belum dilakukan sehingga hasilnya bersifat indikatif. Validasi dengan data plot lapangan dan validasi silang spasial direkomendasikan sebagai pengembangan berikutnya.

# Daftar Isi

Halaman Cover ..... 1
Ringkasan Eksklusif ..... 2
Daftar Isi ..... 3
Daftar Singkatan ..... 4
1.0 Pendahuluan ..... 4
1.1 Latar Belakang ..... 4
1.2 Tujuan ..... 5
1.2 Ruang Lingkup ..... 5
2.0 Tinjauan Teori ..... 6
2.1 GEDI L4A sebagai Referensi Biomassa ..... 6
2.2 Fitur Satelit Multisensor ..... 6
2.3 Random Forest ..... 6
3.0 Data dan Area Studi ..... 7
3.1 Area Studi ..... 7
3.2 Sumber Data ..... 7
3.3 Dataset Pelatihan ..... 8
3.4 Fitur Prediktor ..... 8
4.0 Metodologi ..... 8
4.1 Alur Kerja ..... 8
4.2 Akuisisi Data melalui STAC API ..... 9
4.3 Data Preprocessing dan Feature Engineering ..... 9
4.4 Pemodelan ..... 9
4.5 Strategi Evaluasi ..... 10
4.6 Inferensi Spasial ..... 10
5.0 Hasil dan Pembahasan ..... 11
5.1 Kinerja Model ..... 11
5.2 Feature Importance ..... 11
5.3 Peta AGBD ..... 12
6.0 Keterbatasan ..... 13
7.0 Kesimpulan ..... 13
Daftar Pustaka ..... 14

# Daftar Singkatan

Tabel 1. Daftar singkatan

| Singkatan | Kepanjangan |
|---|---|
| AGBD | *Aboveground biomass Density* |
| STAC | *SpatioTemporal Asset Catalog* |
| GEDI | *Global Ecosystem Dynamics Investigation* |
| SAR | *Syntetic Aperture Radar* |
| GLCM | *Gray-Level Co-occurrence Matrix* |
| DEM | *Digital Elevation Model* |
| RMSE | *Root Mean Sqared Error* |
| MAPE | *Mean Absolute Percentage Error* |
| AOI | *Area of Interest* |
| NIR | *Near Infrared* |
| SWIR | *Shortwave Infrared* |

# 1.0 Pendahuluan

## 1.1 Latar Belakang

Hutan merupakan reservoir karbon daratan yang sangat besar, dan informasi mengenai besarnya cadangan biomassa menjadi dasar dalam pemantauan hutan serta perubahan iklim. *Food and Agriculture Organization* (FAO) memperkirakan luas hutan dunia mencapai 4,06 miliar hektare dengan total stok karbon sekitar 662 gigaton pada tahun 2020, dan hutan tropis menyumbang sekitar 45 persen dari luas tersebut (FAO, 2020). Di Indonesia, pemantauan Kementerian Kehutanan menunjukkan bahwa luas lahan berhutan pada tahun 2024 mencapai 95,5 juta hektare atau 51,1 persen dari total daratan, sementara deforestasi netto pada tahun yang sama tercatat sebesar 175,4 ribu hektare (Kementerian Kehutanan, 2025). Pada skala kabupaten, Kabupaten Bogor memiliki luas sekitar 2.990 km² dan dihuni oleh lebih dari 5,5 juta jiwa (BPS Kabupaten Bogor, 2024), dengan lanskap yang beragam, mulai dari dataran rendah di bagian utara hingga kawasan pegunungan di bagian selatan yang berbatasan dengan Taman Nasional Gunung Gede Pangrango dan Taman Nasional Gunung Halimun Salak. Kondisi tersebut menuntut tersedianya informasi AGBD yang kontinu secara spasial untuk mendukung pemantauan stok karbon dan degradasi hutan.

Meskipun kebutuhan akan informasi biomassa cukup tinggi, pengukurannya pada skala regional masih menghadapi sejumlah kendala. Inventarisasi lapangan konvensional memerlukan biaya yang besar, waktu pengerjaan yang panjang, dan hanya mencakup plot yang terbatas sehingga tidak efisien untuk diterapkan pada skala kabupaten. Pemanfaatan data satelit juga masih menghadapi beberapa kendala. Sensor optik mengalami saturasi pada biomassa tinggi dan terganggu oleh tutupan awan yang sering terjadi di wilayah tropis, sensor radar SAR sensitif terhadap geometri lereng, sedangkan LiDAR GEDI hanya menyediakan nilai AGBD pada jejak titik berdiameter sekitar 25 meter yang tersebar tidak merata dan nilainya merupakan hasil estimasi model, bukan pengukuran lapangan (Duncanson et al., 2022). Selain itu, penggabungan berbagai sumber data dari penyedia yang berbeda kerap memerlukan proses pengunduhan dan penyelarasan secara manual yang sulit direproduksi.

Permasalahan tersebut dapat diatasi melalui pendekatan fusi multisensor yang menggunakan titik GEDI L4A sebagai label pelatihan bagi model pembelajaran mesin, dengan data Sentinel-2, Sentinel-1, elevasi, dan tutupan lahan sebagai prediktor. Data optik memberikan informasi spektral vegetasi, radar menangkap struktur kanopi dan relatif tidak terpengaruh oleh awan, DEM menggambarkan kondisi topografi, dan Dynamic World memberikan informasi tutupan lahan sehingga keterbatasan satu sumber data dapat diimbangi oleh sumber lainnya. Dengan pendekatan ini, observasi GEDI yang bersifat diskret dapat diperluas menjadi estimasi AGBD yang kontinu secara spasial. Akses data melalui antarmuka STAC API pada *Planetary Computer* milik Microsoft dan *Common Metadata Repository* milik NASA mendukung alur kerja pengolahan data yang terbuka, terprogram, dan dapat direproduksi.

Proyek ini menerapkan pendekatan tersebut untuk membangun pemetaan AGBD secara kontinu di Kabupaten Bogor. Data multisumber diselaraskan pada grid beresolusi 30 meter dalam sistem koordinat UTM Zona 48S dan diolah untuk membentuk fitur prediktor yang konsisten secara spasial. Fitur prediktor kemudian dipasangkan dengan label AGBD untuk melatih dan mengevaluasi model Random Forest Regressor. Model yang telah dibangun digunakan untuk melakukan inferensi AGBD pada setiap piksel, sedangkan informasi tutupan lahan digunakan untuk mengecualikan area nonvegetasi. Melalui tahapan tersebut, proyek ini dirancang untuk menghasilkan estimasi AGBD yang kontinu secara spasial dengan memanfaatkan informasi komplementer dari berbagai sumber data dalam suatu alur kerja yang terprogram dan dapat direproduksi.

### 1.2 Tujuan

Berdasarkan permasalahan yang telah dipaparkan dalam latar belakang, tujuan proyek ini disusun sebagai berikut:

- Membangun alur kerja akuisisi dan pengolahan data multisensor melalui STAC API untuk menghasilkan 34 fitur prediktor pada wilayah Kabupaten Bogor.
- Melatih dan mengevaluasi model Random Forest Regressor untuk memprediksi AGBD pada data uji menggunakan metrik $R^2$, RMSE, RMSE relatif, MSE, dan MAPE.
- Menghasilkan peta estimasi AGBD beresolusi 30 meter untuk tahun 2025.

### 1.2 Ruang Lingkup

Agar pelaksanaan proyek tetap terarah dan sesuai dengan tujuan yang telah ditetapkan, ruang lingkup proyek dibatasi sebagai berikut:

- Wilayah studi adalah wilayah administrasi Kabupaten Bogor, Jawa Barat, dengan resolusi spasial 30 meter pada sistem koordinat UTM Zona 48S (EPSG:32648).
- Data latih mencakup periode 25 Maret 2024 hingga 1 Juli 2025, sedangkan inferensi spasial dilakukan untuk tahun 2025 pada wilayah sampel.
- Estimasi AGBD dalam satuan Mg/ha menggunakan 34 fitur dari Sentinel-1, Sentinel-2, DEM GLO-30, dan Dynamic World dengan label GEDI L4A, serta dievaluasi dengan pembagian *random split* 80:20 menggunakan model Random Forest.
- Proyek ini tidak mencakup validasi dengan data plot lapangan, perbandingan sistematis dengan algoritma lain, analisis perubahan biomassa multitemporal, dan validasi silang spasial.

# 2.0 Tinjauan Teori

## 2.1 GEDI L4A sebagai Referensi Biomassa

*Global Ecosystem Dynamics Investigation* (GEDI) adalah instrumen LiDAR yang dipasang di Stasiun Luar Angkasa Internasional. Produk GEDI L4A menyediakan estimasi AGBD pada jejak titik observasi dengan diameter sekitar 25 meter. Nilai AGBD pada produk ini dihasilkan dari model prediksi berbasis metrik gelombang balik LiDAR yang dikembangkan oleh Duncanson et al. (2022). Penting untuk dipahami bahwa nilai AGBD pada produk GEDI L4A merupakan hasil estimasi model, bukan pengukuran lapangan langsung. Ketidakpastian pada nilai label ini secara langsung memengaruhi batas akurasi yang dapat dicapai oleh model regresi yang dilatih menggunakan label tersebut.

## 2.2 Fitur Satelit Multisensor

Sentinel-2 adalah satelit optik multispektral yang menyediakan citra dengan resolusi 10 hingga 60 meter. Band reflektansi permukaan Sentinel-2 mencakup spektrum tampak, near infrared, red edge, dan shortwave infrared yang kaya informasi mengenai kondisi vegetasi. Indeks vegetasi seperti NDVI, GNDVI, EVI, IRECI, dan RVI diturunkan dari kombinasi aritmetika band-band tersebut untuk mengukur kerapatan dan kesehatan vegetasi secara tidak langsung.

Sentinel-1 adalah satelit SAR yang memancarkan dan menangkap gelombang mikro. Hamburan balik radar dalam polarisasi VV dan VH bersifat sensitif terhadap struktur tiga dimensi kanopi dan volume vegetasi, terutama polarisasi silang VH yang merespons hamburan volume dalam tajuk pohon. Fitur tekstur GLCM yang diturunkan dari citra SAR mengkuantifikasi heterogenitas spasial permukaan kanopi berupa nilai kontras, entropi, dan korelasi pada jendela piksel tertentu.

Copernicus DEM GLO-30 menyediakan data ketinggian permukaan bumi dengan resolusi 30 meter. Turunan topografi berupa kemiringan lereng dan arah hadap lereng dihitung dari data DEM. Parameter topografi ini berkorelasi dengan distribusi biomassa melalui pengaruhnya terhadap kondisi iklim mikro, ketersediaan air, dan intensitas paparan cahaya.

Dynamic World adalah produk klasifikasi tutupan lahan hampir-waktu-nyata berbasis model deep learning TensorFlow yang dilatih pada citra Sentinel-2 (Brown et al., 2022). Model ini menghasilkan probabilitas untuk sembilan kelas tutupan lahan, di mana probabilitas tutupan vegetasi berkayu diharapkan berkorelasi positif dengan nilai AGBD.

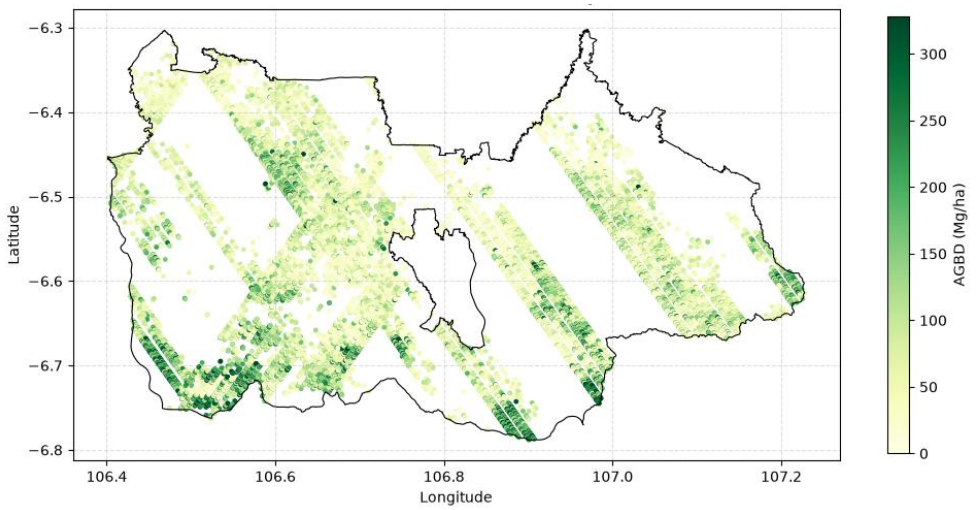
## 2.3 Random Forest

Random Forest (Breiman, 2001) adalah metode *ensemble* yang membangun sejumlah besar pohon keputusan secara paralel, masing-masing dilatih pada subset data yang diambil secara acak dengan penggantian. Prediksi akhir diperoleh dari rata-rata prediksi seluruh pohon. Metode ini dipilih karena kemampuannya menangani hubungan non-linear antara fitur dan target, ketahanannya terhadap overfitting, kemampuannya bekerja tanpa normalisasi fitur, dan kemampuannya menghasilkan ukuran kepentingan fitur yang membantu interpretasi model.

# 3.0 Data dan Area Studi

## 3.1 Area Studi

Area studi yang dipilih untuk pelaksanaan proyek ini mencakup keseluruhan wilayah administrasi Kabupaten Bogor yang secara geografis terletak di Provinsi Jawa Barat, Indonesia. Untuk memastikan konsistensi spasial, seluruh rangkaian proses pengolahan data raster maupun vektor diproyeksikan ke dalam sistem referensi koordinat universal Transverse Mercator (UTM) Zona 48S dengan kode EPSG:32648, serta distandarisasi pada resolusi spasial 30 meter. Berdasarkan batasan administratif tersebut, dimensi grid spasial yang dihasilkan memiliki ukuran matriks sebesar 1.804 piksel pada sumbu vertikal (tinggi) dan 3.054 piksel pada sumbu horizontal (lebar), yang secara penuh melingkupi seluruh lanskap Kabupaten Bogor.




Gambar 1. Peta sebaran titik sampel data latih pada wilayah Kabupaten Bogor

## 3.2 Sumber Data

Untuk mengakomodasi kompleksitas lanskap tropis yang beragam, pengolahan data dalam proyek ini menerapkan pendekatan fusi multisensor. Tabel 2 merangkum secara terperinci seluruh sumber data satelit yang digunakan, platform akses digital yang diandalkan, serta peran spesifik masing-masing dataset dalam pembentukan fitur prediktor.

Tabel 2. Sumber data satelit dan platform akses

| Dataset | Platform Akses | Peran |
|---|---|---|
| Sentinel-2 L2A | Microsoft Planetary Computer melalui STAC API | Band reflektansi dan indeks vegetasi |
| Sentinel-1 RTC | Microsoft Planetary Computer melalui STAC API | Hamburan balik radar VV/VH dan tekstur GLCM |
| DEM GLO-30 | Microsoft Planetary Computer melalui STAC API | Elevasi, kemiringan lereng, dan arah hadap |
| Dynamic Word | Microsoft Planetary Computer melalui STAC API | Probabilitas delapan kelas tutupan lahan |
| GEDI L4A | NASA Earthdata melalui CMR STAC | Label AGBD |

### 3.3 Dataset Pelatihan

Konstruksi dataset pelatihan dibangun berdasarkan data observasi GEDI level 4A yang direkam dalam rentang waktu operasional antara 25 Maret 2024 hingga 1 Juli 2025. Proses penyaringan titik observasi GEDI dilakukan secara ketat dengan memfilter parameter kualitas, di mana hanya titik yang memiliki nilai penanda kualitas l4_quality_flag bernilai satu serta memiliki nilai AGBD berhingga dan valid yang diloloskan. Titik-titik sampel GEDI yang telah lolos tahap verifikasi kualitas tersebut selanjutnya diekstraksi dan dipetakan secara spasial ke posisi piksel grid terdekat. Melalui koordinat yang bersesuaian, nilai label AGBD ini kemudian disandingkan dan digabungkan dengan matriks nilai fitur raster yang diturunkan dari seluruh sensor pendukung.

### 3.4 Fitur Prediktor

Sebagai fondasi pembelajaran model regresi, proses pemodelan ini didukung oleh total 34 fitur prediktor yang diklasifikasikan secara sistematis ke dalam enam kategori utama. Pengelompokan ini dirancang untuk menangkap berbagai dimensi karakteristik permukaan bumi, mulai dari aspek spektral, struktural, topografi, hingga konteks tutupan lahan. Rincian lengkap mengenai distribusi kategori beserta jumlah fitur disajikan pada Tabel 3.

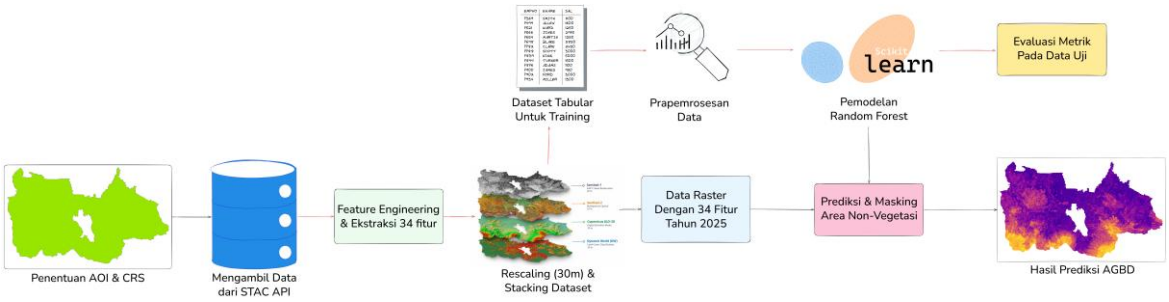
Tabel 3. Kategori fitur prediktor

| Kategori | Jumlah Fitur | Nama Fitur |
|---|---|---|
| Pita spektral Sentinel-2 | 9 | B2, B3, B4, B5, B6, B7, B8, B11, B12 |
| Indeks vegetasi dan kelembapan | 6 | NDVI, GNDVI, EVI, DVI, RVI |
| Hamburan radar SAR | 2 | VV, VH |
| Tekstur GLCM SAR | 6 | VV cont, VV ent, VV corr, VH cont, VH ent, VH corr |
| Topografi | 3 | DEM, Slope, Aspect |
| Probabilitas Tutupan Lahan | 8 | Water, Trees, Grass, Flooded Vegetation, Crops, Shrub & Scrub, Built, Bareland |
| **Total** | **34** | - |

## 4.0 Metodologi

### 4.1 Alur Kerja

Proyek ini diimplementasikan secara terstruktur ke dalam tiga tahapan utama yang masing-masing dijalankan melalui berkas notebook Jupyter yang berbeda. Alur kerja secara keseluruhan dimulai dari pencarian serta pengunduhan data melalui STAC API, dilanjutkan dengan pengolahan dan ekstraksi fitur, pelaksanaan pelatihan serta evaluasi model, dan diakhiri dengan inferensi spasial beserta penyimpanan peta hasil prediksi. Tahap pertama dilaksanakan melalui create_dataset.ipynb yang bertanggung jawab penuh atas akuisisi data dari berbagai sumber, pengolahan data raster menjadi fitur spasial, dan pembentukan dataset tabular. Tahap kedua dijalankan melalui modelling.ipynb yang mencakup analisis data eksploratoris, pelatihan model, serta evaluasi kinerja, sedangkan tahap ketiga diimplementasikan melalui inference.ipynb untuk melakukan inferensi spasial pada seluruh piksel area studi guna menghasilkan peta AGBD berformat GeoTIFF.




Gambar 2. Alur kerja pemodelan AGBD

### 4.2 Akuisisi Data melalui STAC API

Proses akuisisi data memanfaatkan pustaka *pystac-client* dan *planetary-computer* untuk berinteraksi secara langsung dengan antarmuka STAC API. Pencarian data Sentinel-2 L2A menggunakan kriteria batas area studi, rentang waktu yang telah ditentukan, serta ambang batas tutupan awan maksimal sepuluh persen, di mana hasil pencarian diurutkan dari tingkat tutupan awan terendah guna memprioritaskan kualitas visual scene terbaik. Sementara itu, pencarian data Sentinel-1 RTC menggunakan filter orbit descending untuk menjamin konsistensi geometri akuisisi, dan data DEM GLO-30 dicari berdasarkan irisan area studi tanpa filter temporal karena sifatnya yang statis.

Data GEDI L4A diakses melalui klien CMR STAC milik NASA dengan autentikasi kredensial NASA Earthdata yang tersimpan aman dalam berkas .env. Setiap *granule* GEDI berformat HDF5 diunduh ke direktori sementara, dibaca menggunakan pustaka h5py, dan diekstrak nilai atributnya pada kanal pengamatan yang relevan, di mana titik di luar area studi disaring menggunakan batas poligon administrasi. Seluruh berkas raster simpanan menggunakan format GeoTIFF berkompresi deflate yang dilengkapi mekanisme checkpoint berbasis ekstensi sementara *.part* untuk menjamin keutuhan berkas meskipun terjadi gangguan saat pengunduhan.

### 4.3 Data Preprocessing dan Feature Engineering

Seluruh data raster direproyeksi ke dalam sistem koordinat UTM Zona 48S pada resolusi spasial 30 meter menggunakan fungsi reproyeksi rasterio, dengan nilai piksel kosong yang ditandai sebagai NaN. Komposit median temporal dihitung secara per-piksel dari seluruh scene tersedia dengan mengabaikan nilai NaN untuk meredam anomali akibat awan atau atmosfer. Indeks vegetasi diturunkan dari kombinasi band spektral Sentinel-2, sedangkan fitur tekstur GLCM Sentinel-1 dihitung pada jendela piksel lima kali lima setelah kuantisasi nilai desibel SAR menjadi 64 tingkat abu-abu. Parameter topografi diturunkan via gradien numerik DEM, dan probabilitas tutupan lahan Dynamic World diperoleh dari inferensi TensorFlow pada potongan citra Sentinel-2 berukuran 170 kali 170 piksel secara bertahap per ubin guna efisiensi memori.

### 4.4 Pemodelan

Pemodelan regresi dalam proyek ini dibangun menggunakan algoritma RandomForestRegressor dari pustaka scikit-learn. Pemilihan arsitektur ini didasarkan pada kemampuannya dalam menangani hubungan non-linear yang kompleks dan ketahanannya terhadap risiko overfitting. Konfigurasi hiperparameter spesifik yang diterapkan pada model ini dirancang secara terukur untuk mengoptimalkan kinerja pelatihan. Rincian lengkap mengenai parameter tersebut disajikan pada Tabel 4 di bawah ini.

Tabel 4. Konfigurasi hiperparameter model

| Parameter | Nilai | Penjelasan |
|---|---|---|
| n_estimators | 350 | Jumlah pohon keputusan |
| max_features | 1,0 | Seluruh 34 fitur dipertimbangkan pada setiap pemisahan simpul |
| min_samples_leaf | 2 | Setiap simpul daun minimal berisi dua sampel untuk membatasi *overfitting* |
| max_samples | 0,632 | Setiap pohon dilatih pada 63,2 persen sampel hasil *bootstrap* |
| random_state | 42 | Nilai awal acak untuk memastikan hasil dapat direproduksi |

Nilai max_features yang ditetapkan sebesar 1,0 berarti bahwa seluruh 34 fitur dipertimbangkan pada setiap pemisahan simpul. Keragaman antarpohon dalam ansambel bergantung sepenuhnya pada subsampling data melalui mekanisme max_samples. Model yang telah dilatih disimpan dalam format *pickle* pada jalur models/randomforest.pkl.

### 4.5 Strategi Evaluasi

Evaluasi kinerja model dilakukan secara ketat menggunakan data uji independen yang tidak diikutsertakan dalam fase pelatihan. Dataset dibagi secara acak dengan proporsi 80 persen data latih dan 20 persen data uji melalui fungsi scikit-learn dengan parameter random_state bernilai 42 guna menjamin aspek deterministik dan reprodusibilitas. Pengukuran performa regresi dijabarkan menggunakan beberapa metrik statistik utama. Definisi serta satuan dari masing-masing metrik evaluasi tersebut diuraikan secara rinci pada Tabel 5.

Tabel 5. Penjelasan Metrik Evaluasi

| Metrik | Penjelasan | Satuan |
|---|---|---|
| $R^2$ | Proporsi variasi target yang dijelaskan oleh model | - |
| RMSE | Akar dari rata-rata kuadrat galat prediksi | Mg/ha |
| Relative RMSE | RMSE dibagi rata-rata AGBD dikali 100 persen | Persen |
| MSE | Rata-rata kuadrat galat prediksi | $(Mg/ha)^2$ |
| MAPE | Rata-rata galat absolut persentase | Persen |

### 4.6 Inferensi Spasial

Inferensi spasial dilaksanakan melalui berkas inference.ipynb dengan mengekstrak seluruh lapisan fitur pada resolusi 30 meter untuk keseluruhan grid area studi. Matriks fitur dua dimensi diratakan menjadi satu dimensi untuk membentuk tabel data dan piksel yang mengandung nilai NaN pada satu atau lebih fitur diidentifikasi serta dikecualikan dari proses prediksi melalui penerapan masker piksel valid. Model melakukan estimasi nilai AGBD pada piksel yang memiliki kelengkapan data penuh dan hasil prediksi tersebut direkonstruksi kembali ke dalam format matriks dua dimensi sesuai dimensi grid spasial. Tahap pascapemrosesan dilakukan dengan menyematkan masking berdasarkan peta tutupan lahan Dynamic World di mana piksel yang terklasifikasi sebagai area non-vegetasi meliputi badan air kawasan terbangun dan lahan terbuka ditetapkan bernilai nol. Hasil akhir berupa peta sebaran AGBD tersebut disimpan dalam format GeoTIFF.

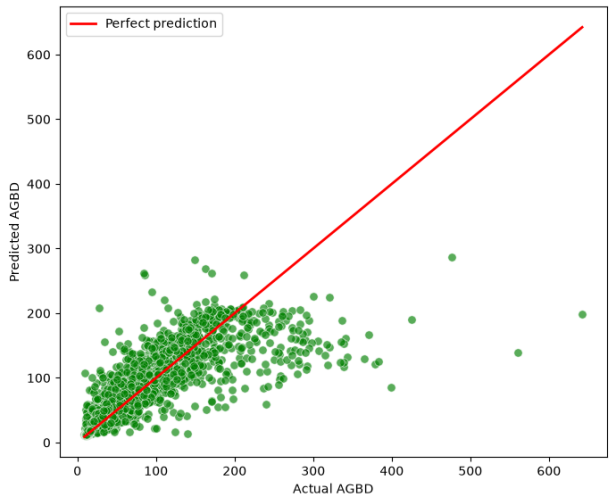
# 5.0 Hasil dan Pembahasan

## 5.1 Kinerja Model

Tabel 6. Hasil metrik evaluasi model

| Metrik | Nilai |
|---|---|
| $R^2$ | 0,6460 |
| RMSE | 39,07 Mg/ha |
| Relative RMSE | 50,31 % |
| MSE | 1.526,16 $(Mg/ha)^2$ |
| MAPE | 32,93 % |

Evaluasi kinerja model pada data uji disajikan secara terperinci melalui perolehan metrik statistik yang terangkum pada Tabel 6. Berdasarkan hasil pengujian tersebut, model regresi menghasilkan nilai koefisien determinasi atau $R^2$ sebesar 0,646 yang menunjukkan bahwa sebagian besar variasi target dapat dijelaskan dengan baik oleh model. Selain itu, nilai Root Mean Squared Error tercatat sebesar 39,07 Mg/ha atau setara dengan 50,31 persen secara relatif, sementara Mean Absolute Percentage Error berada pada angka 32,93 persen.

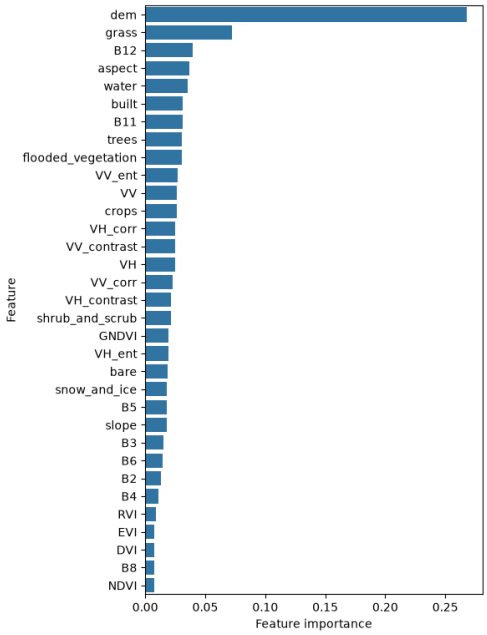



Gambar 2. Perbandingan nilai AGBD prediksi dan aktual

Visualisasi perbandingan antara nilai AGBD hasil prediksi model dan nilai aktual pada data uji dapat diamati melalui Gambar 2. Grafik tersebut mengindikasikan bahwa model mampu menangkap pola umum sebaran biomassa secara keseluruhan, meskipun masih terdapat tingkat deviasi pada beberapa rentang nilai tertentu. Galat yang relatif besar ini dipengaruhi oleh faktor kejenuhan sinyal optik pada biomassa tinggi, perbedaan skala spasial antara jejak GEDI dan grid piksel, serta ketidakpastian yang melekat pada label referensi.

## 5.2 Feature Importance

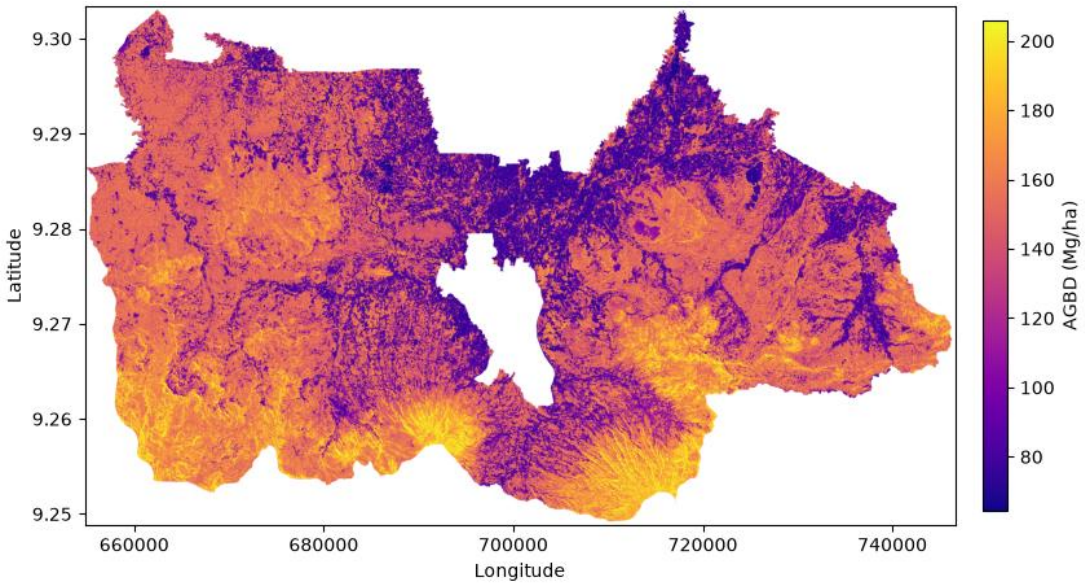
Analisis tingkat kepentingan fitur terhadap proses prediksi model Random Forest ditunjukkan melalui visualisasi peringkat pada Gambar 3. Berdasarkan ukuran penurunan ketidakmurnian, variabel topografi khususnya elevasi DEM memiliki pengaruh yang sangat dominan karena berkaitan erat dengan zonasi vegetasi dan gradien iklim mikro di kawasan pegunungan. Di samping itu, fitur radar Sentinel-1 terutama polarisasi silang dan turunan teksturnya memberikan kontribusi penting dalam merefleksikan struktur tiga dimensi kanopi, sementara probabilitas tutupan lahan dari Dynamic World memperkuat konteks spasial yang relevan dengan potensi biomassa.




Gambar 3. Peringkat kepentingan 34 fitur prediktor pada model *Random Forest*

### 5.3 Peta AGBD

Distribusi spasial hasil estimasi kerapatan biomassa di atas permukaan tanah untuk wilayah Kabupaten Bogor pada tahun 2025 disajikan dalam bentuk peta spasial beresolusi 30 meter. Peta tersebut menggambarkan variasi nilai AGBD yang mencerminkan perbedaan karakteristik tutupan lahan dan kondisi fisiografis di berbagai wilayah Kabupaten Bogor.




Gambar 4. Peta estimasi AGBD Kabupaten Bogor tahun 2025

Berdasarkan sebaran spasial pada peta tersebut, kawasan dengan nilai AGBD tinggi umumnya terpusat di wilayah selatan yang berbatasan langsung dengan kawasan konservasi dan pegunungan, yang mana kondisi hutannya masih terjaga secara alami. Sebaliknya, kawasan perkotaan, lahan pertanian intensif, serta permukiman di bagian utara menunjukkan nilai biomassa yang rendah atau bernilai nol secara mutlak. Nilai nol pada area tersebut diperoleh secara sistematis melalui penerapan masking area non-vegetasi menggunakan model klasifikasi Dynamic World, sehingga badan air dan

kawasan terbangun tidak lagi memuat nilai biomassa yang keliru. Peta ini pada akhirnya berfungsi sebagai produk estimasi regional awal yang dihasilkan dari inferensi model berbasis data multi-sensor untuk periode 2024 hingga 2025.

## 6.0 Keterbatasan

Pelaksanaan proyek estimasi biomassa ini tidak terlepas dari sejumlah kendala teknis maupun metodologis yang memengaruhi tingkat ketelitian hasil akhir. Berbagai batasan tersebut mencakup aspek kualitas data label, metode validasi, hingga karakteristik sensor yang digunakan. Rincian lengkap mengenai faktor keterbatasan, dampak yang ditimbulkan, serta usulan langkah mitigasi untuk pengembangan selanjutnya disajikan secara komprehensif pada Tabel 6.

Tabel 7. Keterbatasan proyek, dampak, dan langkah mitigasi yang disarankan

| Aspek | Keterbatasan | Dampak | Saran Mitigasi |
|---|---|---|---|
| Label referensi | Nilai AGBD GEDI L4A merupakan estimasi model, bukan pengukuran lapangan | Akurasi absolut tidak dapat diverifikasi secara independen | Validasi dengan data plot inventarisasi lapangan |
| Metode validasi | Pembagian data secara acak pada data yang berautokorelasi spasial | Skor evaluasi berpotensi berbeda dari kinerja nyata | Validasi silang spasial atau *cross validation* |
| Sinkronisasi waktu | Selisih waktu antara akuisisi GEDI, komposit citra, dan periode inferensi | Ketidaksesuaian kondisi vegetasi antara label dan fitur | Penyempitan jendela waktu akuisisi data |
| Saturasi sinyal | Sensor optik mengalami saturasi pada nilai biomassa tinggi | Kecenderungan miskalkulasi pada prediksi nilai AGBD tinggi | Penambahan fitur dan transformasi variabel target |
| Ketergantungan layanan | Alur kerja bergantung pada ketersediaan layanan STAC API eksternal | Alur kerja dapat terganggu jika layanan tidak tersedia | Penyimpanan data lokal sebagai cadangan |

## 7.0 Kesimpulan

Alur kerja akuisisi dan pengolahan data multisensor berbasis STAC API berhasil dibangun secara sistematis untuk menghasilkan 34 fitur prediktor pada grid beresolusi 30 meter di wilayah Kabupaten Bogor. Variabel prediktor tersebut mencakup data spektral serta indeks vegetasi dari Sentinel-2, hamburan balik radar beserta tekstur GLCM dari Sentinel-1, parameter topografi dari Copernicus DEM GLO-30, serta probabilitas tutupan lahan dari Dynamic World. Melalui pelatihan model Random Forest dengan 350 pohon keputusan, sistem menghasilkan nilai koefisien determinasi $R^2$ sebesar 0,646 dan Root Mean Squared Error sebesar 39,07 Mg/ha pada data uji, yang menunjukkan bahwa model memiliki kemampuan memadai untuk menangkap pola distribusi biomassa regional secara umum.

Peta sebaran AGBD beresolusi 30 meter untuk tahun 2025 berhasil dibentuk dengan mengintegrasikan proses inferensi spasial dan penerapan masking area non-vegetasi menggunakan klasifikasi Dynamic World. Peta akhir yang dihasilkan memperlihatkan variasi spasial kerapatan biomassa yang konsisten dengan kondisi fisiografis wilayah kajian, di mana nilai tinggi terpusat di kawasan pegunungan selatan dan nilai rendah atau nol mendominasi kawasan perkotaan di bagian utara.

Meskipun demikian, hasil ini bersifat indikatif dan berfungsi sebagai estimasi regional awal mengingat label referensi bersumber dari estimasi model GEDI serta belum dilakukannya validasi lapangan secara langsung.

## Daftar Pustaka

BPS Kabupaten Bogor, *Kabupaten Bogor Dalam Angka 2025*. Bogor: Badan Pusat Statistik Kabupaten Bogor, 2025.

L. Breiman, "Random Forests," *Machine Learning*, vol. 45, hlm. 5 hingga 32, 2001.

C. F. Brown et al., "Dynamic World, Near real-time global 10 m land use land cover mapping," *Scientific Data*, vol. 9, 2022.

R. Dubayah et al., "The Global Ecosystem Dynamics Investigation: High-resolution laser ranging of the Earth's forests and topography," *Science of Remote Sensing*, vol. 1, 2020.

L. Duncanson et al., "Aboveground biomass density models for NASA's Global Ecosystem Dynamics Investigation (GEDI) lidar mission," *Remote Sensing of Environment*, vol. 270, 2022.

Food and Agriculture Organization of the United Nations, *Global Forest Resources Assessment 2020: Main Report*. Roma: FAO, 2020. https://doi.org/10.4060/ca9825en.

Kementerian Kehutanan Republik Indonesia, "Hasil pemantauan hutan Indonesia tahun 2024," keterangan resmi, 21 Maret 2025.

F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, 2011.

Microsoft Planetary Computer Documentation. Tersedia di https://planetarycomputer.microsoft.com/docs. Diakses pada Oktober 2026.